


Chat com documentos usando LLM (RAG)

Apresentação de um sistema simples que usa um modelo de linguagem para responder perguntas com base em documentos fornecidos.

Disciplina: Tópicos Especiais de Inteligência Artificial

Tema: Retrieval Augmented Generation (RAG)



O problema dos LLMs

Modelos de linguagem grandes (LLMs) são muito poderosos, mas possuem algumas limitações importantes:

O conhecimento pode estar desatualizado

O modelo não conhece documentos privados

O modelo pode inventar respostas (alucinação)

Exemplo: Se perguntarmos algo específico sobre um documento interno, o modelo pode não ter acesso a essa informação.

Por isso precisamos de uma forma de conectar o LLM com dados externos.

A ideia do RAG

RAG significa **Retrieval Augmented Generation**.

É uma técnica que combina duas coisas:

1

Busca de informação em documentos relevantes

2

Geração de texto com LLM

Funcionamento:

Pergunta → buscar documentos relacionados → enviar contexto para o LLM → gerar resposta.

Assim, o modelo responde usando informações que não estavam no treinamento original.

Arquitetura do sistema

Fluxo do sistema:

01

Coleção de documentos

02

Conversão dos textos em embeddings

03

Armazenamento em um banco vetorial

04

Quando chega uma pergunta:

- gerar embedding da pergunta
- buscar documentos semelhantes
- enviar pergunta + contexto ao LLM

05

O LLM gera a resposta final

Essa abordagem é muito usada em chatbots corporativos e sistemas de busca semântica.

Tecnologias usadas

Para implementar um exemplo simples usamos:

Sentence Transformers

gera embeddings semânticos

FAISS

biblioteca para busca rápida de vetores

Flan-T5

modelo de linguagem para geração de respostas

Python + Google Colab

ambiente de execução

Embeddings

Embeddings são representações numéricas de textos.

Exemplo:

"futebol" → vetor numérico

"jogo" → vetor próximo

Textos com significados parecidos ficam próximos no espaço vetorial.

Isso permite buscar documentos semanticamente semelhantes.

Busca vetorial

Depois de transformar os documentos em embeddings:

- armazenamos os vetores
- quando chega uma pergunta:
 - o transformamos a pergunta em vetor
 - o procuramos os vetores mais próximos

Essa busca retorna os documentos mais relevantes para a pergunta.

Integração com o LLM

Os documentos encontrados são enviados para o modelo como contexto.

Exemplo de prompt:

📄 **Contexto:**

(doc 1)

(doc 2)

Pergunta: O que são embeddings?

O modelo então gera uma resposta baseada nesses documentos.

Demonstração

Agora vamos ver uma demonstração prática no Colab.

O sistema irá:

1 carregar alguns documentos

2 criar embeddings

3 buscar documentos relevantes

4 usar um LLM para gerar respostas

Conclusão

RAG permite:

- usar LLMs com dados próprios
- reduzir alucinações
- construir chatbots inteligentes

Aplicações reais:

chat com PDFs

suporte técnico

busca semântica

assistentes corporativos